

# Automatisation de la vérification des faits

BELKHIRI Taha

TIPE

# Introduction

# Sommaire

- ▶ Généralités sur les graphes de connaissances
- ▶ Construction d'un graphe de connaissances
- ▶ Valeur de vérité et calibrage
- ▶ Réflexion et conclusion
- ▶ Annexe

# Généralités sur les graphes de connaissances

- ▶ Le graphe de connaissances représente une collection de descriptions interconnectées d'entités
- ▶ Un graphe de connaissances est un ensemble de triplets (sujet, prédicat, objet).
- ▶ Le sujet et l'objet sont représentés par deux sommets différents, le prédicat représente l'arête qui les lie.

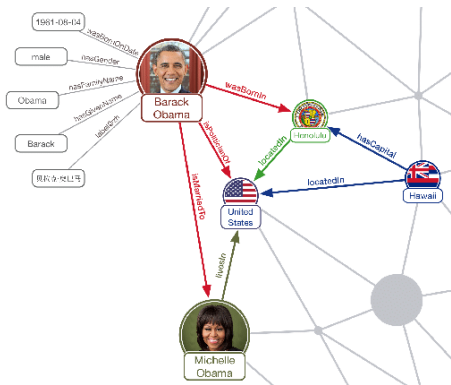


Figure 1: Représentation d'un graphe de connaissances

# Construction d'un graphe de connaissance

a- À partir du dump Wikidata:

- ▶ Contient plus de 90.000.000 éléments
- ▶ 60Gb de données
- ▶ Contient des informations non pertinentes pour la construction du graphe de connaissances

b- Construction dynamique:

- ▶ Plus simple et plus facile à manier
- ▶ Ne demande pas autant d'espace
- ▶ Délocalisée

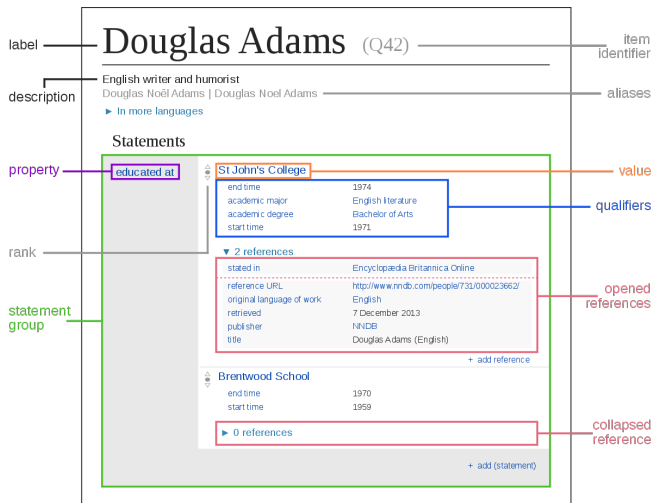


Figure 2: Modèle de données dans Wikidata

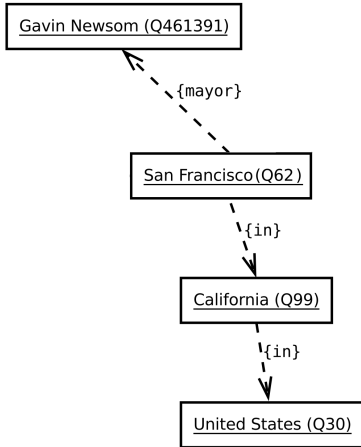


Figure 3: Construction d'une chaîne de données liées à partir de Wikidata






Figure 4: Recherche d'un chemin entre Mark Zuckerberg et les Illuminatis

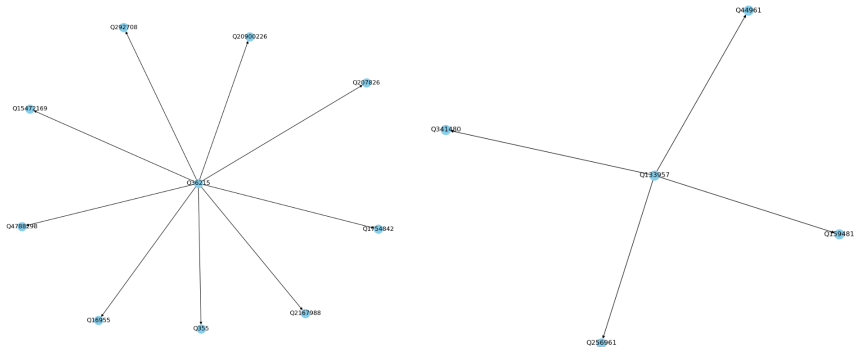



Figure 5: Première étape de la construction du graphe



# Valeur de vérité

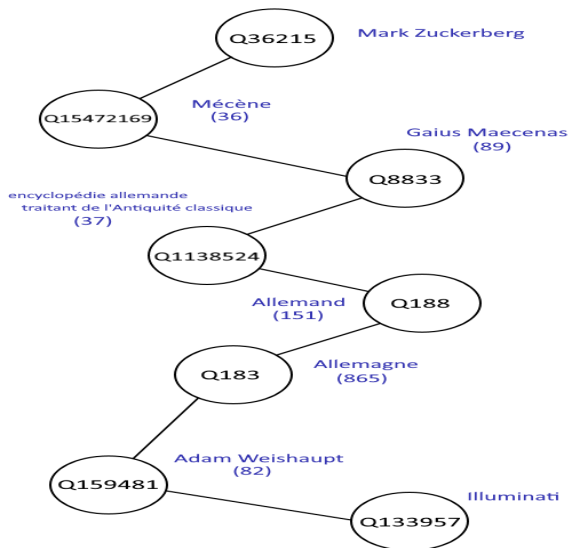


Figure 7: Un chemin entre Mark Zuckerberg et les Illuminati

- ▶ On associe à chaque proposition  $p$ ,  $v(p)$  la valeur de vérité de  $p$
- ▶  $v(p) \in [0, 1]$
- ▶ Soit  $N = \max_{i \in [1, n]} \{(N_i)\}$   
Alors

$$v(p) = \frac{1}{1 + K(N)\log(N)}$$

- ▶  $K(N) = 6,8 \cdot 10^{-3} \times N + 0,2$
- ▶  $v(\text{"Mark Zuckerberg est Illuminati"}) = \frac{1}{1 + K(865)\log(865)} = 0.053014027820469774$





Figure 8: Comparaison sans/avec calibrage

Réflexion et conclusion

# Annexe

```
from wikidata.sparql import return_sparql_query_results
import networkx as nx
import spacy
from json.decoder import JSONDecodeError
from math import log10
nlp = spacy.load("fr_core_news_sm")

def filter(target):
    if target.isdigit():
        return None
    doc = nlp(target)
    sentence_ents = [str(ent) for ent in doc.ents if ent.label_]
    sentence_punct = [None for token in doc if token.is_punct]
    if len(sentence_ents) != 0 and len(sentence_punct) == 0:
        if target[:7] != "http://":
            return target
```



```

def sujet_to_wd(sujet):
    sujet_str = '' + sujet + ''
    query_string = """
        SELECT ?item
    WHERE
    {
        ?item rdfs:label "" + sujet_str + ""@fr
    }
    """
    res = return_sparql_query_results(query_string)
    for row in res["results"]["bindings"]:
        try:
            value = row["item"]["value"]
            if value[:31] == "http://www.wikidata.org/entity/":
                return value[31:]
        except IndexError:
            error = True

```

```

def wikidata_query(sujet_wd):
    query_string = """
SELECT distinct ?wdLabel ?ps_Label {
    VALUES (?sujet) {(wd:"" + sujet_wd + "")}
    # Item Property Value
    ?sujet ?p ?statement .
    ?statement ?ps ?ps_ .
    ?wd wikibase:claim ?p.
    ?wd wikibase:statementProperty ?ps.
    OPTIONAL {
        ?statement ?pq ?pq_ .
        ?wdpq wikibase:qualifier ?pq .
    }
    SERVICE wikibase:label { bd:serviceParam wikibase:language "fr" }
} ORDER BY ?wd ?statement ?ps_
LIMIT 50
    """

```

```

res = return_sparql_query_results(query_string)
source = []
relations = []
target = []
for row in res["results"]["bindings"]:
    target_nl = row["ps_Label"]["value"]
    if filter(target_nl) != None and filter(target_nl) != "":
        try:
            node_wd = sujet_to_wd(target_nl)
        except JSONDecodeError:
            error = True
            node_wd = None

        if node_wd != None and node_wd != sujet_wd and node_wd != "":
            source.append(sujet_wd)
            relations.append(row["wdLabel"]["value"])
            target.append(node_wd)

return [sujet_wd, target, relations, len(target)]

```

```
def has_same_element(L1,L2):  
    for x in L1:  
        for y in L2:  
            if x == y:  
                return True  
    return False  
  
def build_graph(sujet_wd,target_wd):  
    QUERY1 = [wikidata_query(sujet_wd)]  
    QUERY2 = [wikidata_query(target_wd)]  
    LIST1 = QUERY1[0][1]  
    LIST2 = QUERY2[0][1]  
    while not has_same_element(LIST1,LIST2):  
        visited = []  
        tmp1 = []  
        tmp2 = []
```

```

for x in LIST1:
    if x not in visited:
        visited.append(x)
        if x != None:
            try:
                query = wikidata_query(x)
                tmp1 = tmp1 + query[1]
                QUERY1.append(query)
            except JSONDecodeError:
                error = True
for y in LIST2:
    if y not in visited:
        visited.append(y)
        if y != None:
            try:
                query = wikidata_query(y)
                tmp2 = tmp2 + query[1]
                QUERY1.append(query)
            except JSONDecodeError:
                error = True
LIST1 = LIST1 + tmp1
LIST2 = LIST2 + tmp2
return QUERY1 + QUERY2

```

```

def valeur_verite(sujet_wd,target_wd):
    Q = build_graph(sujet_wd,target_wd)
    T0 = []
    T1 = []
    T2 = []
    for x in Q:
        for i in range(x[3]):
            T0.append(x[0])
            T1.append(x[1][i])
            T2.append(x[2][i])
    G = nx.Graph()
    for i in range(len(T0)):
        G.add_edge(T0[i], T1[i])
    p = nx.shortest_path(G,sujet_wd, target_wd)
    N = max([wikidata_query(x)[3] for x in p[1:len(p)-1]])
    a = 6.8 * 10 ** (-3)
    b = 0.2
    return 1/(1+(a*N+b)*log10(N))

```